西北工业大学

《模式识别与机器学习》
实验报告

学　　号 **2024302696**

姓　　名 张洛宾

实验六：基于线性回归的医疗保险费用预测

一、 实验目的

1. 掌握线性回归模型的基本原理，理解其在连续数值预测任务中的应用方法。
2. 学习医疗保险费用预测任务中的数据预处理流程，包括训练集和测试集划分、类别特征编码以及目标变量建模。
3. 使用年龄、性别、BMI、子女人数、是否吸烟和地区等特征建立线性回归模型，对个人医疗保险费用进行预测。
4. 输出模型在测试集上的均方误差 MSE、均方根误差 RMSE、平均绝对误差 MAE 和决定系数 R^2等评价指标。

二、 实验原理

1. 线性回归简介

线性回归是一种常用的监督学习回归算法，主要用于预测连续型数值变量。其基本思想是假设输入特征与输出目标之间存在近似线性关系，通过学习各个特征对应的权重系数，建立输入变量与目标变量之间的映射关系。

在线性回归模型中，设输入特征为 x1, x2, ..., xn，目标变量为 y，则模型可以表示为：

$$y = w_1x_1 + w_2x_2 + \cdots + w_nx_n + b$$

其中，w1,w2,...,wn 表示各输入特征对应的回归系数，b 表示偏置项。对于本实验，目标变量 y 为医疗保险费用 charges，输入特征包括 age、sex、bmi、children、smoker 和 region。

线性回归模型通过最小化预测值与真实值之间的误差来学习参数。常用的损失函数为均方误差，即：

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

其中，yi 表示真实医疗保险费用，ŷi 表示模型预测费用，n 表示测试样本数量。

2. 类别特征编码

本实验数据集中既包含数值型特征，也包含类别型特征。其中，age、bmi、children 为数值型特征；sex、smoker、region 为类别型特征。线性回归模型无法直接处理字符串形式的类别变量，因此需要对类别特征进行数值化编码。

本实验采用独热编码方法处理类别特征。独热编码会将一个类别变量转换为多个 0/1 特征。例如，smoker 特征包含 yes 和 no 两类，经过编码后可以用 smoker_yes 表示是否吸烟。当 smoker_yes = 1 时，表示该样本为吸烟者；当 smoker_yes = 0 时，表示该样本为非吸烟者。

通过独热编码，类别变量可以被转换为模型能够处理的数值特征，从而参与线性回归建模。

3. 模型评价指标

本实验使用 MSE、RMSE、MAE 和 R^2 对模型预测效果进行评价。

MSE 表示均方误差，用于衡量预测值与真实值之间的平方误差平均值。MSE 越小，说明模型预测结果越接近真实值。

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

RMSE 表示均方根误差，是 MSE 的平方根。RMSE 与原始费用单位一致，更便于理解预测误差大小。

$$RMSE = \sqrt{MSE}$$

MAE 表示平均绝对误差，用于衡量预测值与真实值之间绝对误差的平均水平。

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

R^2表示决定系数，用于衡量模型对目标变量变化的解释能力。R^2越接近 1，说明模型拟合效果越好。

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

三、 实验步骤和程序流程

本实验使用 Python 语言和 PyTorch 深度学习框架完成。实验主要环境如下：

项目	配置
编程语言	Python
主要库	pandas、numpy、matplotlib、scikit-learn
模型	LinearRegression
数据集	医疗保险费用数据集
样本数量	1338
特征数量	6 个输入特征，1 个目标变量
训练集比例	80%
测试集比例	20%
随机种子	random_state = 42

1. 数据读取

首先使用 pandas 读取医疗保险费用数据集。数据集包含 1338 条样本和 7 个字段，字段如下：

字段名	含义	类型
Age	年龄	数值型
Sex	性别	类别型
Bmi	身体质量指数	数值型
Children	子女人数	数值型
Smoker	是否吸烟	类别型
Region	所在地区	类别型
Charges	医疗保险费用	目标变量

读取数据后，检查缺失值情况。实验数据集中各字段均无缺失值，因此不需要额外进行缺失值填充或删除处理。

2. 数据预处理

将 charges 作为目标变量 y，其余字段作为输入特征 X。然后对数据进行训练集和测试集划分，测试集比例设置为 20%。

对于数值型特征 age、bmi、children，直接输入模型。对于类别型特征 sex、smoker、region，采用 One-Hot Encoding 进行编码，使其转换为线性回归模型可以处理的数值形式。

实验中的数据处理流程如下图：



图 1：实验流程示意图

3. 模型训练

实验使用 scikit-learn 中的 LinearRegression 建立线性回归模型。训练阶段使用训练集拟合模型参数，测试阶段使用测试集计算预测结果。

模型训练过程可以概括为：

1. 输入训练集特征；
2. 对类别变量进行独热编码；
3. 使用线性回归模型学习各特征的权重系数；
4. 在测试集上进行费用预测；
5. 计算预测结果与真实费用之间的误差。

4. 主要程序代码

代码详见附件中 project6.py。

四、 实验结果

1. 数据基本情况

本实验所使用的数据集共有 1338 条样本，包含 6 个输入特征和 1 个目标变量。输入特征包括 age、sex、bmi、children、smoker 和 region，目标变量为 charges。

经检查，数据集中不存在缺失值，因此不需要进行缺失值填充处理。数据基本统计情况如下：

特征	均值	最小值	最大值
Age	39.21	18	64
Bmi	30.66	15.96	53.13
Children	1.09	0	5
Charges	13270.42	1121.87	63770.43

2. 模型评价结果

使用 80% 数据作为训练集，20% 数据作为测试集。在线性回归模型训练完成后，在测试集上得到如下结果：

评价指标	数值
MSE	33596915.85
RMSE	5796.28
MAE	4181.19
R^2	0.7836

从实验结果可以看出，模型的 R^2 为 0.7836，说明线性回归模型能够解释约 78.36% 的医疗保险费用变化。整体来看，模型具有一定预测能力，但仍存在一定误差。

MSE 数值较大的原因是医疗保险费用本身数值范围较大，且部分样本费用明显高于平均水平。相比 MSE，RMSE 和 MAE 更直观。实验中 RMSE 为 5796.28，MAE 为 4181.19，说明模型预测费用与真实费用之间仍存在数千元级别的平均误差。

3. 特征系数结果

线性回归模型得到的主要特征系数如下：

特征	回归系数
smoker_yes	23651.13
region_southwest	-809.80
region_southeast	-657.86
children	425.28
region_northwest	-370.68
bmi	337.09
age	256.98
sex_male	-18.59

从回归系数可以看出，是否吸烟对医疗保险费用影响最大。在其他因素保

持不变的情况下，吸烟者的医疗保险费用预测值明显高于非吸烟者，系数约为23651.13。这说明吸烟状态是影响医疗保险费用的重要因素。

年龄的系数为256.98，说明在其他条件相同的情况下，年龄每增加1岁，预测保险费用平均增加约256.98。BMI的系数为337.09，说明BMI每增加1个单位，预测保险费用平均增加约337.09。子女人数的系数为425.28，也表现出一定正向影响，但整体影响小于吸烟、年龄和BMI。

性别变量sex_male的系数较小，说明在本模型中，性别对医疗保险费用的直接影响不明显。地区变量的系数为负，说明与基准地区相比，部分地区的预测费用略低，但其影响程度明显小于是否吸烟。

4. 可视化结果分析

从年龄与医疗保险费用散点图（图1）可以看出，随着年龄增加，医疗保险费用整体呈上升趋势。这与线性回归模型中age的正系数一致。年龄越大，个体潜在健康风险和医疗支出可能越高，因此保险费用也更容易增加。

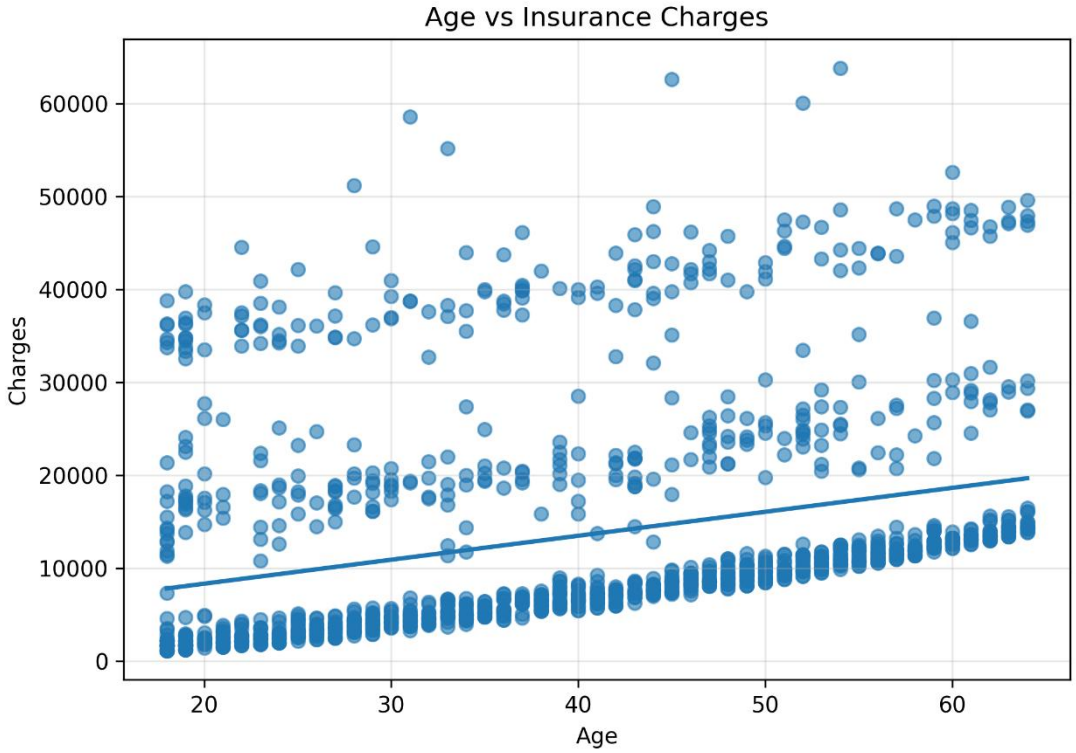


图2： 年龄与医疗保险费用关系图

从BMI与医疗保险费用散点图（图2）可以看出，BMI与医疗保险费用之间也存在一定正相关关系。BMI较高的人群，可能存在更高的健康风险，因此医疗保险费用也可能更高。不过，从散点分布来看，BMI对费用的影响并不是单独决定性的，其影响可能会与是否吸烟、年龄等因素共同作用。

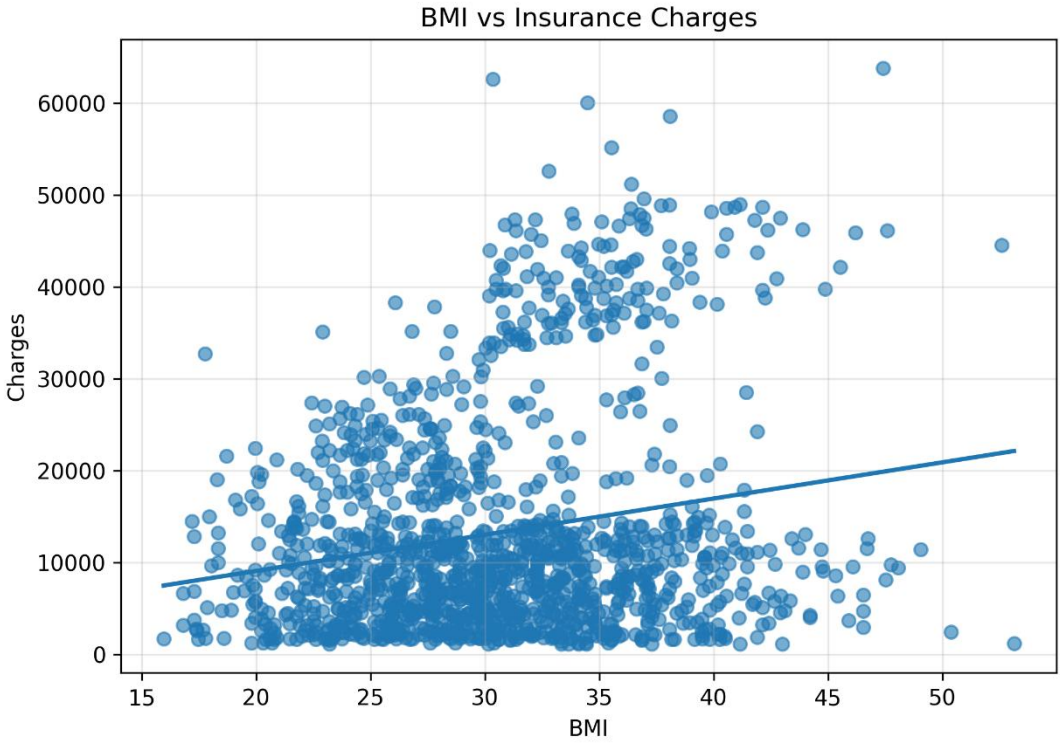


图 3： BMI 与医疗保险费用关系图

从是否吸烟与医疗保险费用的箱线图（图 4）可以看出，吸烟者的保险费用整体显著高于非吸烟者。非吸烟者的费用分布主要集中在较低区间，而吸烟者费用中位数和整体分布范围均明显更高。这一结果与线性回归系数分析一致，说明是否吸烟是本数据集中影响医疗保险费用的最重要因素。

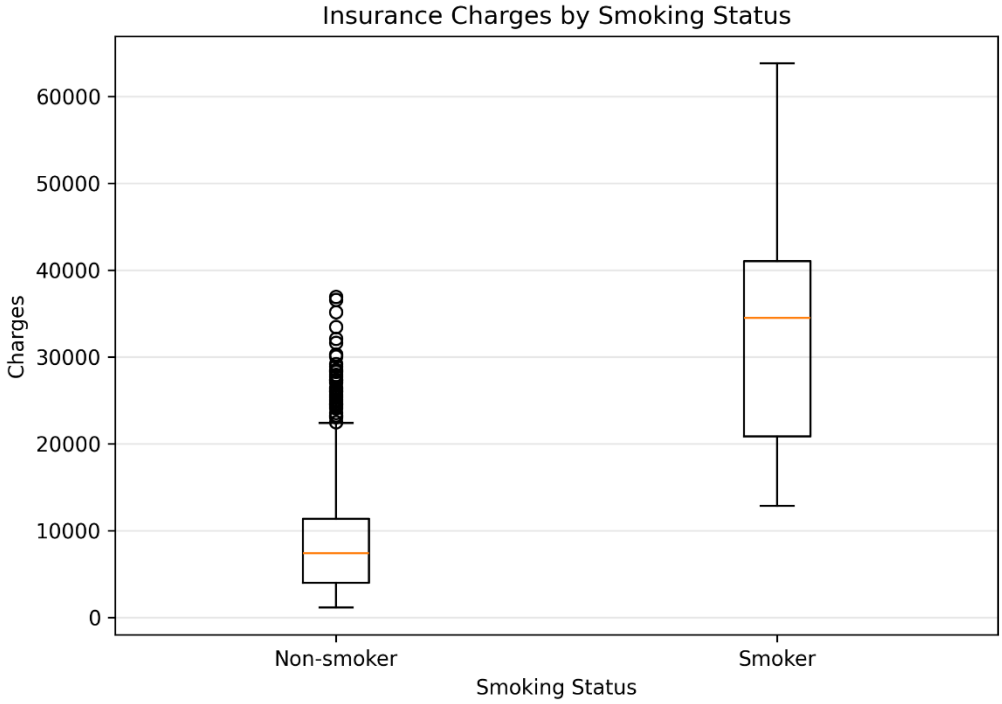


图 4： 是否吸烟与医疗保险费用关系图

通过特征系数图（图 5）可以更加直观地观察不同特征对模型预测结果的影响。smoker_yes 的系数远高于其他特征，说明吸烟状态对预测费用的贡献最大。age 和 bmi 均为正系数，说明年龄和 BMI 增加会推动预测费用上升。sex_male 的系数接近 0，说明性别变量在该线性模型中的影响较弱。

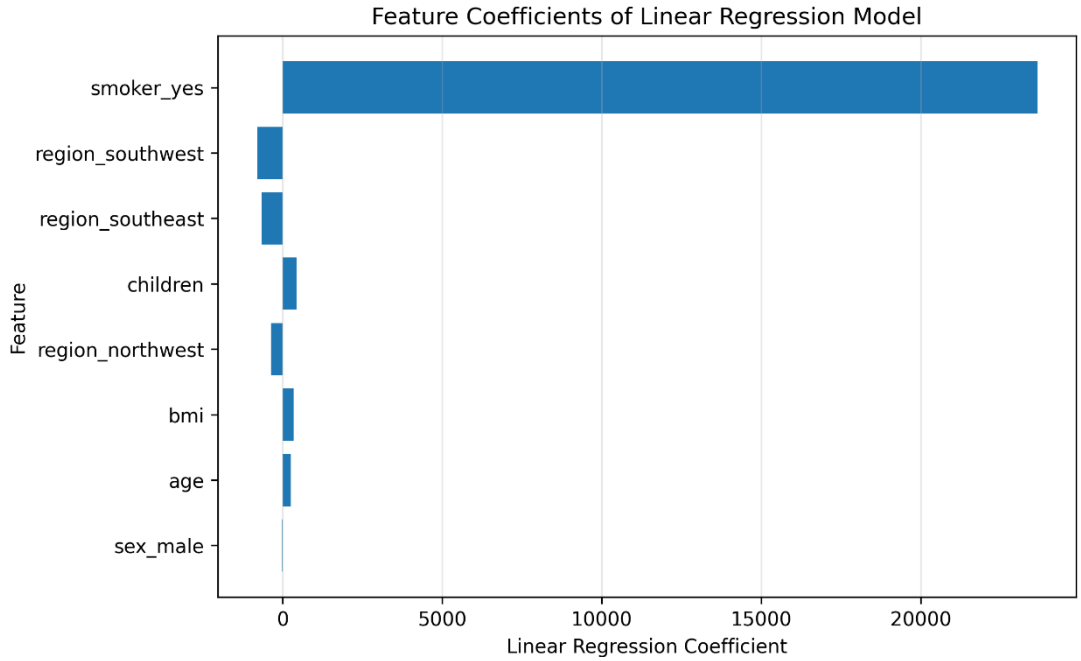


图 5 线性回归模型特征系数图

五、 评价分析

1. 模型预测效果分析

本实验使用线性回归模型对医疗保险费用进行预测，测试集上的 R^2 为 0.7836，说明模型能够解释大部分费用变化。对于一个基础线性回归模型而言，该结果说明输入特征与保险费用之间确实存在较明显的统计关系。

但是，模型的 RMSE 为 5796.28，MAE 为 4181.19，说明模型仍存在一定预测误差。这主要与医疗保险费用数据本身的复杂性有关。医疗费用不仅受到年龄、BMI、吸烟等因素影响，还可能受到既往疾病、地区医疗水平、保险条款和个体健康状况等未包含变量的影响。因此，仅使用当前几个基础特征建立线性模型，难以完全准确预测每个个体的费用。

2. 年龄因素影响分析

年龄是医疗保险费用的重要影响因素之一。实验中 age 的回归系数为正，说明年龄增加会导致预测保险费用上升。从散点图也可以看出，年龄较大的样本整体费用更高。这一现象符合实际情况，因为随着年龄增长，个体患病风险和医疗

支出通常会上升，保险费用也会相应增加。

不过，年龄并不是唯一决定因素。同一年龄段样本之间的费用差异仍然较大，说明还存在其他因素影响保险费用。

3. BMI 因素影响分析

BMI 的回归系数同样为正，说明 BMI 增加会推动预测保险费用上升。BMI 反映个体体重与身高之间的关系，较高的 BMI 可能与肥胖、代谢疾病以及慢性病风险相关，因此会对医疗保险费用产生影响。

但从可视化结果看，BMI 与保险费用之间的线性关系不如是否吸烟明显。部分 BMI 较高的样本费用并不一定很高，而部分 BMI 中等的样本也可能具有较高费用。这说明 BMI 对费用的影响可能需要结合吸烟状态、年龄等因素共同分析。

4. 是否吸烟因素影响分析

是否吸烟是本实验中最重要的影响因素。模型中 smoker_yes 的回归系数约为 23651.13，远高于其他特征。这说明在控制年龄、BMI、子女人数、性别和地区等因素后，吸烟者的预测医疗保险费用仍显著高于非吸烟者。

从箱线图可以看出，吸烟者的费用分布整体上移，中位数和高费用样本数量都明显高于非吸烟者。这表明吸烟状态对医疗费用具有很强的解释能力，是保险费用预测中的关键特征。

5. 模型不足与改进方向

虽然线性回归模型具有结构简单、可解释性强、训练速度快等优点，但它也存在一定局限性。

第一，线性回归假设输入特征与目标变量之间是线性关系，而实际医疗保险费用可能受到复杂非线性因素影响。例如，BMI 对费用的影响可能在超过某一阈值后才明显增加，年龄和吸烟状态之间也可能存在交互作用。

第二，当前模型没有显式考虑特征交互。例如，吸烟者中 BMI 较高的人群可能具有更高费用风险，但普通线性回归模型未直接建模这种组合效应。

第三，数据集中的特征数量较少，缺少既往病史、疾病类型、保险计划类型、收入水平等可能影响医疗费用的重要因素，因此模型预测能力存在上限。

后续可以尝试以下改进方向：

1. 增加特征交互项，例如 smoker×bmi、age×smoker；
2. 尝试多项式回归，增强模型对非线性关系的表达能力；
3. 使用岭回归或 Lasso 回归，提升模型稳定性；
4. 尝试随机森林、梯度提升树等非线性模型，提高预测精度；
5. 对 charges 进行对数变换，缓解费用分布偏态带来的影响。

六、 实验总结

本实验基于医疗保险费用数据集，使用线性回归模型对个人医疗保险费用进行了预测。实验首先对数据进行读取和缺失值检查，然后将类别型特征进行独热编码，并按照 8:2 的比例划分训练集和测试集。随后建立线性回归模型，在测试集上计算 MSE、RMSE、MAE 和 R^2 等评价指标。

实验结果表明，线性回归模型在测试集上的 R^2 为 0.7836，说明模型能够较好地解释医疗保险费用的变化趋势。从特征系数和可视化结果可以看出，是否吸烟是影响医疗保险费用的最重要因素，年龄和 BMI 也对费用具有正向影响，而性别和地区的影响相对较弱。

总体来看，线性回归模型具有实现简单、训练速度快和结果可解释性强的优点，适合作为医疗保险费用预测任务的基础模型。但由于医疗费用受多种复杂因素影响，单一线性模型仍存在一定误差。若希望进一步提升预测精度，可以在后续实验中引入非线性模型和特征交互项进行改进。

附 1:参考文献

[1] Hastie T, Tibshirani R, Friedman J. The elements of statistical learning[J]. 2009.
[2] James G, Witten D, Hastie T, et al. An introduction to statistical learning: with applications in R[M]. New York: springer, 2013.
[3] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine learning in Python[J]. the Journal of machine Learning research, 2011, 12: 2825-2830.
[4] Bishop C M, Nasrabadi N M. Pattern recognition and machine learning[M]. New York: springer, 2006.